



Classificação de doenças em folhas de Mandioca



Isabel Salles – 188790
Victor Luigi – 250955
Rafael Feltrin – 276246
Bruno Salles – 281129



Introdução

Contextualização

- 2ª maior fonte de carboidrato da África
- Cultivada principalmente por pequenos agricultores e essencial para segurança alimentar
- Doenças virais reduzem significativamente a produtividade
- Diagnóstico depende de especialistas agrícolas

Desafio Kaggle

- Classificação de doenças em folhas de mandioca
- Fotografias tiradas por agricultores e rotuladas por especialistas
- 21.367 imagens rotuladas
- 4 categorias de doenças e 1 indicando a folha saudável



Desafio Kaggle: Problemas

- Ruído de Labels
- Desbalanceamento de Classes (70% em uma única classe)
- Imagens amadoras:
 - ruídos de iluminação,
 - múltiplos ângulos
 - fundos complexos

Exemplos





Abordagem e Métodos

Técnicas de Regularização e Desempenho

Data Augmentation

- Transformações geométricas e fotométricas
 - Rotações, espelhamentos horizontais e verticais, alterações de brilho, contraste, saturação, cortes aleatórios, redimensionamento e perturbações locais.
- Objetivo de simular variações que poderiam estar presentes nas fotos tiradas no campo

Label smoothing

- Substitui distribuições de probabilidade concentradas por suavizadas
- Reduz a confiança excessiva do modelo nas previsões
- Útil em conjuntos com rótulos possivelmente ruidosos
- Evita penalizações extremas quando o modelo não atribui probabilidade quase unitária ao rótulo anotado

CutMix

- Regiões de uma imagem são substituídas por de outra, com combinação proporcional dos rótulos
- Força o modelo a não depender de uma única área discriminativa ou do contexto global da imagem

Segmentação baseada em cor

- Objetivo de reduzir a influência do fundo
- Manter regiões compatíveis com a folha e atenuar elementos externos

TTA - Test-Time Augmentation

- Técnica aplicada apenas na inferência
- A mesma imagem é avaliada várias vezes com pequenas transformações:
 - flips horizontais/verticais
 - crops ou center crops
 - rotações leves
 - diferentes visões da mesma folha

TTA - Test-Time Augmentation

- As probabilidades finais são obtidas pela média das previsões
- Atua como um “ensemble interno” de uma única rede
- Resultado observado:
 - ResNet50 + Label Smoothing melhorou com TTA: 87.29% → 88.03%
 - EfficientNet-B3 segmentada piorou com TTA: 88.29% → 88.06%
 - CropNet + crop-TTA obteve 89.31%

Modelos

Baseline

- Transfer Learning
- ResNet50 pré-treinada na ImageNet
- Imagens redimensionadas para 224×224
- Fine-tuning por 30 épocas, batch size 32
- Camada final linear com 5 saídas
- Acurácia de validação: aproximadamente 85%

Backbone + Head

- ResNet50 e EfficientNetB3 como extrator de atributos congelado
- (Head) Classificação por métodos como:
 - SVM
 - XGBoost
 - MLP simples

Os atributos pré-treinados em ImageNet seriam suficientemente informativos para separar as doenças?

Backbone + Head


- ResNet50:
 - Acurácia de 68% no SVM
 - Acurácia de 78% com Dense Layer
 - Acurácia de 75% no XGBoost
- EfficientNetB3:
 -

A adaptação (*fine-tuning*) do backbone ao domínio específico é decisiva para melhorar o desempenho em tarefas de classificação fina, mesmo com o pré-treinamento em ImageNet.

Fine Tunning

Objetivo: reduzir overfitting e
melhorar generalização

**ResNet-50 + CutMix + Label
Smoothing**
**+ Data augmentation + Maior
weight decay**



Acurácia de
validação: 87.29%


EfficientNetB3

- Entrada em maior resolução: 300×300
- Segmentação baseada em cor para reduzir influência do fundo
- CutMix + Label Smoothing + Data Augmentation forte

Objetivos:

- Preserva melhor detalhes finos da folha
- Relevante para manchas pequenas, textura e descoloração
- Reduzir interferência de solo, galhos e outras plantas no fundo

EfficientNet-B3 + CutMix + Label Smoothing
+ Segmentação de cor



Acurácia de validação de **88.29%**

ConvNeXt-Tiny

- Arquitetura convolucional moderna inspirada em avanços trazidos pelos Transformers
- Acurácias de treino superiores a 97%
- Desempenho de validação estabilizou em aproximadamente 87.73%
- Provável tendência a overfitting

CropNet

- Modelo pré-treinado especificamente para doenças em mandioca
- Utilizado diretamente(sem fine-tuning) como classificador externo
- Criado pelo Google

CropNet: Pré-Treinamento Específico

- Geração de um arquivo CSV com as probabilidades previstas pelo CropNet.
- Combinação dessas probabilidades com as do ensemble em PyTorch.
- Separação dos pipelines de TensorFlow e PyTorch.
- Processo mais estável, modular e de fácil manutenção.

CropNet: Pré-Treinamento Específico

- Inferência com *crop-TTA*
 - Cortes e transformações simples, agregando as probabilidades resultantes

CropNet + *crop-TTA*



Acurácia de validação de **89.31%**

Vision Transformers

- Divide a imagem em sub-regiões ***patches*** e aplica o mecanismo de ***Self-Attention***
- Permite que o modelo mapeie o contexto holístico da folha e correlacione pixels distantes desde as camadas iniciais
- Diferenciar patologias com características visuais espalhadas

Vision Transformers

- Arquitetura *vit_base_patch16_384*
- Resolução de 384 x 384
- *Fine-Tuning* ponta a ponta, atualizando todas as suas matrizes de atenção para o domínio da mandioca

Vision Transformers

- Otimizador AdamW
 - Agendador de taxa de aprendizado LambdaLR
 - Normalização e transformações geométricas moderadas
 - Data Augmentation para reduzir overfitting e melhorar generalização espacial
-
- **Objetivo:** estabilizar o treinamento e controlar o decaimento da taxa de aprendizado

Vision Transformers

Melhor desempenho para um modelo individual



Acurácia de validação de **88.60%**

Vision Transformers

- Elevou as métricas das classes minoritárias,
- Alcançou índices de revocação (*recall*) sólidos mesmo para a patologia mais rara
- Mecanismos de atenção global geram representações mais discriminativas do que abordagens baseadas apenas em informações locais


Aprendizado Auto-Supervisionado

Ensemble

Extrair o melhor de cada rede e mitigar falhas individuais


- **EfficientNet-B3:** Foco em texturas e lesões locais.
- **ResNet50:** Maior estabilidade e regularização.
- **ConvNeXt-Tiny:** Aprendizado de representações complementares.
- **CropNet:** Conhecimento de domínio via pré-treinamento específico.

**EfficientNet-B3 segmentada + ResNet50 com CutMix
+ ConvNeXt-Tiny**



Acurácia de validação de **88.90%**


**EfficientNet-B3 segmentada + ResNet50 com CutMix
+ ConvNeXt-Tiny + CropNet**



Acurácia de validação de **90.03%**

Ensemble Final: Top-3 + CropNet

Classificação de Doenças em Folhas de Mandioca



Estratégia: diversidade arquitetural + pré-treinamento específico + fusão ponderada

Análise e Resultados

Submissão Kaggle:



0.9068 - leaderboard público

0.9119 - leaderboard privado

Classificaria em **2º lugar**

The private leaderboard is calculated with approximately 69% of the test data. This competition has completed. This leaderboard reflects the final standings.

Prize Winners

#	△	Team	Members		Score	Entries	Last	Solution
1	—	golddiggaz	  		0.9132	131	5y	
2	▲ 658	Devon Stanfield			0.9043	3	5y	
3	▲ 26	T0m			0.9028	244	5y	

Cassava Leaf Disease Classification

Late Submission

...

Overview Data Code Models Discussion Leaderboard Rules Team Submissions

evaluation. The evaluated submission with the best Private Score is used for your final score.

Submissions evaluated for final score

All Successful Selected Errors

Recent ▾

Submission and Description		Private Score ⓘ	Public Score ⓘ	Selected
	notebook381101ffbe - v5 Succeeded (after deadline) · 4h ago	0.9119	0.9068	☐

	notebook381101ffbe - v5	0.9119	0.9068	☐
---	--------------------------------	--------	--------	--------------------------

Prizes

Leaderboard Prizes: Awarded based on private leaderboard ranking.

- 1st Place - \$8,000
- 2nd Place - \$4,000
- 3rd Place - \$3,000

Abordagem	Técnicas principais	Val. Acc.	Macro-F1
ResNet50 baseline	Transfer learning simples	$\approx 85.0\%$	—
ResNet50 + Label Smoothing + TTA	Regularização + TTA	88.03%	—
ResNet50 + CutMix + Label Smoothing	CutMix, LS, weight decay	87.29%	77.33%
ConvNeXt-Tiny	Label smoothing, aug. forte	87.73%	77.69%
EfficientNet-B3	CutMix, LS, img. 300, segmentação	88.29%	78.57%
ViT	Atenção global, img. 384, TTA	88.60%	—
Ensemble PyTorch Top-3	EffNet + ResNet + ConvNeXT	88.90%	79.27%
CropNet	Pré-treino específico + crop-TTA	89.31%	81.85%
Ensemble final	PyTorch Top-3 + CropNet	$\approx 90.03\%$	83.02%

Análise e resultados

- **CropNet** superou os modelos ajustados localmente, mesmo sem refinamento adicional
- Enquanto a ImageNet traz uma base visual genérica, um modelo pré-treinado em doenças de mandioca já incorpora invariâncias ideais para o problema.
- Técnicas como TTA não são universalmente benéficas
 - **Hipótese:** Transformações geométricas pós-segmentação podem descaracterizar texturas finas e pequenas manchas locais de cor.
 - Ensemble foi essencial porque combinou modelos com erros diferentes

Interpretabilidade

Agenda

- Objetivo: entender por que o modelo toma determinadas decisões
- Técnicas utilizadas:
 - Galeria de erros e incerteza
 - Grad-CAM
 - Grad-CAM direcionado à classe verdadeira
 - Sensibilidade por oclusão
- Perguntas investigadas:
 - O modelo olha para a folha ou para o fundo?
 - Erros ocorrem por ruído de label ou ambiguidade visual?
 - As regiões importantes coincidem com sintomas da doença?

Galeria de Erros e Incerteza

- Agrupamos imagens de validação segundo o comportamento do ensemble
- Categorias analisadas:
 - acertos de alta confiança
 - erros de alta confiança
 - alta entropia
 - baixa probabilidade para o rótulo verdadeiro
 - amostras aleatórias por classe

correct high conf

2278166989.jpg
T=1 CBSD | P=1 CBSD
conf=0.984 ent=0.10



1004389140.jpg
T=1 CBSD | P=1 CBSD
conf=0.979 ent=0.13



240110902.jpg
T=3 CMD | P=3 CMD
conf=0.974 ent=0.16



3401928000.jpg
T=1 CBSD | P=1 CBSD
conf=0.974 ent=0.16



1181473732.jpg
T=1 CBSD | P=1 CBSD
conf=0.973 ent=0.16



630240307.jpg
T=3 CMD | P=3 CMD
conf=0.972 ent=0.17



3779251659.jpg
T=3 CMD | P=3 CMD
conf=0.972 ent=0.17



1753872657.jpg
T=3 CMD | P=3 CMD
conf=0.971 ent=0.17



low true label probability

602031471.jpg
T=3 CMD | P=2 CGM
conf=0.939 ent=0.30



3822534983.jpg
T=2 CGM | P=3 CMD
conf=0.907 ent=0.41



783577117.jpg
T=3 CMD | P=1 CBSD
conf=0.775 ent=0.70



3819082104.jpg
T=1 CBSD | P=2 CGM
conf=0.905 ent=0.43



1654084150.jpg
T=2 CGM | P=3 Healthy
conf=0.959 ent=0.22



72925791.jpg
T=0 CBB | P=4 Healthy
conf=0.805 ent=0.74



1057462029.jpg
T=0 CBB | P=1 CBSD
conf=0.714 ent=0.81



1553857773.jpg
T=2 CGM | P=1 CBSD
conf=0.568 ent=1.03



random per class

3203412332.jpg
T=0 CBB | P=4 Healthy
conf=0.561 ent=1.19



1652157522.jpg
T=0 CBB | P=1 CBSD
conf=0.386 ent=1.40



3944841972.jpg
T=0 CBB | P=0 CBB
conf=0.876 ent=0.53



1081992369.jpg
T=1 CBSD | P=1 CBSD
conf=0.830 ent=0.66



2923119977.jpg
T=1 CBSD | P=1 CBSD
conf=0.408 ent=1.19



1234375577.jpg
T=1 CBSD | P=1 CBSD
conf=0.820 ent=0.68



410291053.jpg
T=2 CGM | P=2 CGM
conf=0.885 ent=0.47



3089605566.jpg
T=2 CGM | P=2 CGM
conf=0.829 ent=0.63



uncertain high entropy

1330510466.jpg
T=2 CGM | P=4 Healthy
conf=0.250 ent=1.57



2202563232.jpg
T=4 Healthy | P=3 CMD
conf=0.301 ent=1.56



1501728003.jpg
T=0 CBB | P=4 Healthy
conf=0.364 ent=1.47



824811574.jpg
T=1 CBSD | P=3 CMD
conf=0.313 ent=1.47



2333079073.jpg
T=4 Healthy | P=4 Healthy
conf=0.314 ent=1.46




2854111497.jpg
T=1 CBSD | P=0 CBB
conf=0.331 ent=1.46



3976477069.jpg
T=4 Healthy | P=1 CBSD
conf=0.378 ent=1.45



1242441980.jpg
T=3 CMD | P=1 CBSD
conf=0.395 ent=1.44



wrong high conf

1654084150.jpg
T=2 CGM | P=3 CMD
conf=0.959 ent=0.22



3254381404.jpg
T=2 CGM | P=3 CMD
conf=0.951 ent=0.26



602031471.jpg
T=3 CGM | P=2 CGM
conf=0.939 ent=0.30



2074036389.jpg
T=2 CGM | P=3 CMD
conf=0.938 ent=0.31



2191616657.jpg
T=4 Healthy | P=3 CMD
conf=0.929 ent=0.34



2203540560.jpg
T=3 CMD | P=1 CBSD
conf=0.926 ent=0.35



2247595260.jpg
T=1 CBSD | P=4 Healthy
conf=0.924 ent=0.37



2703905057.jpg
T=1 CBSD | P=3 CMD
conf=0.920 ent=0.36



Grad-Cam: Acertos e Casos Representativos


- Grad-CAM mostra as regiões mais importantes para a decisão do modelo
- Aplicado ao melhor modelo PyTorch individual: EfficientNet-B3 com segmentação
- Mapas de calor indicam regiões que mais contribuíram para a classe prevista

3401928000.jpg
correct_high_conf | true=1 CBSD | sel_pred=1 CBSD sel_conf=0.974
model_pred=1 CBSD (0.897) | cam_target=1 CBSD


Original



Grad-CAM



Sobreposição




1553857773.jpg
low_true_prob | true=2 CGM | sel_pred=1 CBSD sel_conf=0.568
model_pred=1 CBSD (0.746) | cam_target=2 CGM

Original



Grad-CAM



Sobreposição




3959033347.jpg
per_class | true=0 CBB | sel_pred=4 Healthy sel_conf=0.574
model_pred=4 Healthy (0.913) | cam_target=4 Healthy

Original



Grad-CAM



Sobreposição



Grad-Cam: Direcionado à Classe Verdadeira


- Em erros, também calculamos Grad-CAM usando a classe verdadeira como alvo
- Pergunta: existe evidência visual para o rótulo correto?

2247595260.jpg
wrong_high_conf | true=1 CBSD | sel_pred=4 Healthy sel_conf=0.924
model_pred=4 Healthy (0.908) | cam_target=1 CBSD


Original



Grad-CAM



Sobreposição




1654084150.jpg
wrong_high_conf | true=2 CGM | sel_pred=3 CMD sel_conf=0.959
model_pred=3 CMD (0.911) | cam_target=2 CGM


Original



Grad-CAM



Sobreposição



Sensibilidade por Oclusão


- Técnica complementar ao Grad-CAM
- Mascaramos pequenas regiões da imagem e medimos a queda de confiança
- Se ocultar uma região reduz muito a confiança, essa região era importante para a predição

1654084150.jpg
group=wrong_high_conf | true=2 | model_pred=3 (0.911) | target=3 (0.911)


Original



Occlusion sensitivity



Sobreposição




2247595260.jpg
group=wrong_high_conf | true=1 | model_pred=4 (0.908) | target=4 (0.908)


Original



Occlusion sensitivity



Sobreposição



Conclusão

Resultados

- Melhor validação local: 90.03%
- Kaggle Public Score: 0.9068
- Kaggle Private Score: 0.9119
- Resultado comparável ao 2º lugar do ranking privado
- Ganho total em relação à baseline: aproximadamente +5 pontos percentuais

Melhorias

- 5-fold cross-validation para reduzir dependência de um único split
- ResNeXt50 em resolução 512×512
- Ensemble com mais EfficientNets e ViTs
- Bi-Tempered Loss para lidar com ruído de rótulo
- Confident Learning para remover ou reponderar exemplos suspeitos

